

Analiza wpływu bezrobocia na poziom przestępczości w Polsce

Projekt przygotowali: Anita Carlos, Jakub Marciniak

1. Opis problemu

Bezrobocie i przestępczość to dwa z najważniejszych problemów społeczno-ekonomicznych, które mają ogromny wpływ na stabilność i bezpieczeństwo społeczeństwa. W kontekście Polski, te zjawiska nie tylko wpływają na jakość życia obywateli, ale również na ogólną kondycję ekonomiczną i społeczną kraju. W niniejszym raporcie skupimy się na analizie zależności między bezrobociem a poziomem przestępczości, z naciskiem na przestępczość kryminalną, drogową oraz gospodarczą.

Bezrobocie to stan, w którym osoby zdolne do pracy i aktywnie poszukujące zatrudnienia nie mogą znaleźć odpowiedniego miejsca pracy. Jest to kluczowy wskaźnik kondycji gospodarczej kraju. Wysoki poziom bezrobocia może prowadzić do szeregu negatywnych konsekwencji, takich jak:

- Zwiększone obciążenie systemu opieki społecznej
- Spadek jakości życia
- Zmniejszenie wydajności ekonomicznej

Przestępczość obejmuje wszelkie działania sprzeczne z obowiązującym prawem, które są karalne przez organy ścigania. Przestępstwa można podzielić na różne kategorie, takie jak przestępczość kryminalna (np. kradzieże, rozboje), przestępczość drogowa (np. prowadzenie pojazdu pod wpływem alkoholu, wypadki drogowe) oraz przestępczość gospodarcza (np. oszustwa finansowe, korupcja). Wysoki poziom przestępczości ma poważne konsekwencje dla społeczeństwa, w tym:

- Spadek poczucia bezpieczeństwa
- Koszty ekonomiczne
- Degradacja społeczna

Zależność między bezrobociem a przestępczością jest przedmiotem wielu badań naukowych. Hipoteza głosi, że wyższy poziom bezrobocia może prowadzić do wzrostu przestępczości, ponieważ osoby bez pracy mogą być bardziej skłonne do popełniania przestępstw z powodu frustracji, braku środków do życia lub desperacji. Badania w różnych krajach, w tym w Polsce, sugerują, że istnieje korelacja między tymi dwoma zjawiskami, choć siła i natura tej zależności mogą się różnić w zależności od regionu oraz rodzaju przestępczości.

W niniejszym raporcie przeanalizujemy dane dotyczące bezrobocia oraz przestępczości w Polsce na przestrzeni ostatnich dekad, aby zidentyfikować wzorce i zależności między tymi zjawiskami.

2. Przedstawienie metod rozwiązania problemu

Zbieranie danych

- Pobranie danych historycznych na temat bezrobocia i przestępczości z odpowiednich źródeł
- Usystematyzowanie wstępne danych (określenie czy dane obejmują ten sam okres czasu i mają taką samą częstotliwość)

Przygotowanie danych

- Odpowiednie przygotowanie danych by zachowały ten sam format
- Przeprowadzenie ujednolicenia danych na podstawie ich częstotliwości
- Standaryzacja

Eksploracyjna analiza danych (EDA)

- Przeprowadzenie podstawowych analiz statystycznych
- Wizualizacja danych

Modelowanie statystyczne

- Wybór modelu statystycznego
 - Regresja liniowa
 - Model Arima
- Dopasowanie modeli
- Test t-studenta
- Korelacja Pearsona

Weryfikacja i walidacja modeli

- Testowanie modeli

Interpretacja wyników

3. Opis przebiegu badania

Przebieg badania "Analiza wpływu bezrobocia na przestępczość w Polsce" rozpoczął się od zebrania danych dotyczących stopy bezrobocia oraz liczby przestępstw kryminalnych, gospodarczych i drogowych w Polsce w latach 1999-2021. Dane te zostały wczytane z plików Excel, a następnie

przetworzone, aby uzyskać roczne wartości średnie stopy bezrobocia oraz sumaryczną liczbę przestępstw dla każdego typu w skali kraju.

Pierwszym krokiem była eksploracyjna analiza danych (EDA), która obejmowała statystyki opisowe, takie jak średnia, mediana, odchylenie standardowe i wariancja, dla stopy bezrobocia oraz liczby przestępstw. Na tym etapie wygenerowano również różne wykresy, w tym linie trendu oraz histogramy, aby wizualnie przedstawić zmiany tych zmiennych w czasie.

Następnie dane zostały ustandaryzowane przy użyciu skali standardowej, a zbiory danych zostały podzielone na zestawy treningowe i testowe. Modele regresji liniowej zostały użyte do oceny wpływu stopy bezrobocia na liczbę przestępstw kryminalnych, gospodarczych i drogowych. Efektywność modeli oceniono przy pomocy metryk takich jak średni błąd kwadratowy (MSE) oraz współczynnik determinacji (R^2). Dodatkowo, do analizy korelacji między zmiennymi użyto współczynnika korelacji Pearsona, a do porównania grup (niskie vs. wysokie bezrobocie) zastosowano test t-Studenta.

W celu prognozowania przyszłych wartości liczby przestępstw, zastosowano modele ARIMA, analizując sezonowość i stacjonarność danych za pomocą testu Dickeya-Fullera oraz wykresów ACF i PACF.


Ostatecznie przeprowadzono analizę skupień metodą K-means, aby zidentyfikować wzorce w danych dotyczących przestępstw w zależności od poziomu bezrobocia. Metoda "łokcia" została użyta do określenia optymalnej liczby klastrów, a wyniki wizualizowano na wykresach przedstawiających zależność między bezrobociem a różnymi typami przestępstw.

Badanie zakończyło się próbą prognozowania liczby przestępstw na przyszłość, co dostarczyło dodatkowych wniosków na temat zależności między stopą bezrobocia a przestępczością w Polsce.


4. Rezultaty

Eksploracyjna analiza danych (EDA)


Bezrobocie:



Wykres przedstawia zmiany stopy bezrobocia w Polsce w latach 1999-2021. Na wykresie widoczna jest niebieska linia z punktami oznaczającymi poszczególne lata, a czerwona przerywana linia wskazuje średnią stopę bezrobocia wynoszącą 12.18%. Wartości bezrobocia oscylowały wokół tej średniej, osiągając szczyty w latach 2002 i 2003 oraz spadając do najniższego poziomu w latach 2008 i 2015.




Histogram przedstawia rozkład częstości stopy bezrobocia w Polsce w analizowanym okresie. Na osi poziomej znajdują się różne wartości stopy bezrobocia, a na osi pionowej liczba przypadków (częstość) wystąpienia tych wartości. Najwięcej obserwacji dotyczy bezrobocia na poziomie około 12.5%, co pokrywa się z obliczoną średnią. Widoczny jest również gładki krzyżek częstości (KDE), który pomaga w wizualizacji rozkładu.




Ten wykres, podobnie jak pierwszy, przedstawia zmiany stopy bezrobocia w Polsce, ale dodatkowo zawiera czerwoną przerywaną linię trendu, która wskazuje na ogólną tendencję spadkową. Linia trendu sugeruje, że pomimo okresowych wzrostów i spadków, ogólny poziom bezrobocia w Polsce wykazuje tendencję malejącą w analizowanym okresie.


Przestępstwa kryminalne:



Wykres ilustruje zmiany liczby przestępstw kryminalnych w Polsce od 1990 do 2021 roku. Linia niebieska przedstawia roczną liczbę przestępstw, która na początku okresu była najwyższa, a następnie systematycznie malała, osiągając najniższy poziom w ostatnich latach. Czerwona przerywana linia pokazuje średnią roczną liczbę przestępstw wynoszącą około 774955.



Najwięcej lat charakteryzowało się liczbą przestępstw kryminalnych bliską 500000 i 800000. Sugeruje to, że te wartości są dominujące w analizowanym okresie. Pomimo pewnej zmienności, histogram pokazuje, że liczba lat z wyższą liczbą przestępstw jest znaczna na początku okresu, a następnie spada. To może sugerować ogólną tendencję spadkową w liczbie przestępstw kryminalnych w Polsce.




Linia trendu wskazuje na stały spadek liczby przestępstw kryminalnych w Polsce w analizowanym okresie, co sugeruje ogólną poprawę sytuacji bezpieczeństwa publicznego.

Przestępstwo gospodarcze:




Wykres przedstawia zmiany liczby przestępstw gospodarczych w Polsce od 1999 do 2021 roku. Niebieska linia pokazuje roczną liczbę przestępstw, która wykazuje ogólną tendencję wzrostową, szczególnie widoczną od 2015 roku. Czerwona przerywana linia oznacza średnią liczbę przestępstw wynoszącą około 149595, co pokazuje, że w ostatnich latach liczba przestępstw znacznie przewyższała tę średnią.




Najwięcej lat charakteryzowało się liczbą przestępstw gospodarczych bliską 150000. Sugeruje to, że jest to dominujący poziom przestępczości gospodarczej w analizowanym okresie. Rozkład liczby przestępstw jest dość zróżnicowany, co wskazuje na duże wahania w liczbie przestępstw gospodarczych między różnymi latami. Widać zarówno lata z bardzo niską liczbą przestępstw (poniżej 75000), jak i lata

z bardzo wysoką liczbą (ponad 200000).




Linia trendu wskazuje na systematyczny wzrost liczby przestępstw gospodarczych w analizowanym okresie, co sugeruje, że zjawisko to nasila się z biegiem lat.


Przestępstwa drogowe:



Wykres ilustruje zmiany liczby przestępstw drogowych w Polsce od 1999 do 2021 roku. Linia niebieska przedstawia roczną liczbę przestępstw, która początkowo rośnie, osiągając szczyt w latach 2004-2005, a następnie stopniowo maleje. Czerwona przerywana linia oznacza średnią roczną liczbę przestępstw, wynoszącą około 121076, co pokazuje, że liczba przestępstw była na ogół wyższa od tej średniej w pierwszej połowie analizowanego okresu, a niższa w drugiej połowie.



Histogram pokazuje, że liczba przestępstw drogowych była zmienna, z wyraźnymi pikami w latach, gdy liczba przestępstw była szczególnie wysoka (około 75000 i 175000). To wskazuje na niestabilność w zakresie przestępczości drogowej w różnych latach.



Na początku okresu obserwujemy gwałtowny wzrost liczby przestępstw, osiągający szczyt w latach 2004-2005. Następnie liczba przestępstw zaczyna systematycznie spadać, osiągając najniższe wartości w ostatnich latach analizowanego okresu. Linia trendu wskazuje na ogólną tendencję spadkową, co sugeruje, że liczba przestępstw drogowych maleje z biegiem czasu.

Modelowanie statystyczne

```

#Wybór kolumn do standaryzacji
kolumny = ["Bezrobocie [%]", "Liczba przestępstw kryminalnych", "Liczba przestępstw drogowych",
"Liczba przestępstw gospodarczych"]

scaler = StandardScaler()
df_merged[kolumny] = scaler.fit_transform(df_merged[kolumny])

X = df_merged[["Bezrobocie [%]"]]
y_kr = df_merged[["Liczba przestępstw kryminalnych"]]
y_dro = df_merged[["Liczba przestępstw drogowych"]]
y_gosp = df_merged[["Liczba przestępstw gospodarczych"]]

#Podział na zbiory treningowe i testowe
X_train, X_test, y_kr_train, y_kr_test = train_test_split(X, y_kr, test_size = 0.2,
random_state=42)
_, _, y_dro_train, y_dro_test = train_test_split(X, y_dro, test_size = 0.2, random_state=42)
_, _, y_gosp_train, y_gosp_test = train_test_split(X, y_gosp, test_size = 0.2, random_state=42)

#Model regresji liniowej dla przestępczości kryminalnej
model_kr = LinearRegression()
model_kr.fit(X_train, y_kr_train)
y_kr_pred = model_kr.predict(X_test)

#Model regresji liniowej dla przestępczości drogowej
model_dro = LinearRegression()
model_dro.fit(X_train, y_kr_train)
y_dro_pred = model_dro.predict(X_test)

#Model regresji liniowej dla przestępczości gospodarcze
model_gosp = LinearRegression()
model_gosp.fit(X_train, y_kr_train)
y_gosp_pred = model_gosp.predict(X_test)

```

Regresja liniowa:

Przestępstwa kryminalne:

- Średni błąd kwadratowy (MSE): 0.8477
- Współczynnik determinacji (R^2): 0.082

Interpretacja: Model regresji kryminalnej ma niską wartość R^2 , co oznacza, że tylko 8.2% zmienności w liczbie przestępstw kryminalnych jest wyjaśniane przez zmienność stopy bezrobocia. Model nie jest dobrze dopasowany do danych, co sugeruje, że inne czynniki mogą mieć większy wpływ na przestępczość kryminalną.

Przestępstwa drogowe:

- Średni błąd kwadratowy (MSE): 1.7963
- Współczynnik determinacji (R^2): -0.5404

Interpretacja: Model regresji drogowej ma ujemne R^2 , co sugeruje, że model nie tylko nie wyjaśnia zmienności liczby przestępstw drogowych, ale jest gorzej dopasowany niż model średniej. Wynik ten wskazuje na bardzo słabe dopasowanie modelu do danych.

Przestępstwa gospodarcze::

- Średni błąd kwadratowy (MSE): 2.333
- Współczynnik determinacji (R^2): -0.599

Interpretacja: Podobnie jak w przypadku przestępstw drogowych, model regresji gospodarczej ma ujemne R^2 , co oznacza, że model jest bardzo słabo dopasowany do danych i nie wyjaśnia zmienności liczby przestępstw gospodarczych. Wynik sugeruje, że zmienność w przestępczości gospodarczej jest niezależna od stopy bezrobocia.

```
#Korelacja Pearsona
corr_kryminalne, _ = pearsonr(df_merged["Bezrobocie [%]"], df_merged["Liczba przestępstw kryminalnych"])
corr_drogowe, _ = pearsonr(df_merged["Bezrobocie [%]"], df_merged["Liczba przestępstw drogowych"])
corr_gospodarcze, _ = pearsonr(df_merged["Bezrobocie [%]"], df_merged["Liczba przestępstw gospodarczych"])
```

Korelacja Pearsona:

- Korelacja dla przestępstw kryminalnych: 0.8513

Interpretacja: Wysoka dodatnia korelacja (0.8513) sugeruje, że istnieje silny związek pomiędzy stopą bezrobocia a liczbą przestępstw kryminalnych. Wzrost stopy bezrobocia jest związany ze wzrostem liczby przestępstw kryminalnych.

- Korelacja dla przestępstw drogowych: 0.603

Interpretacja: Średnia dodatnia korelacja (0.603) wskazuje na umiarkowany związek między stopą bezrobocia a liczbą przestępstw drogowych. Oznacza to, że wyższe bezrobocie jest umiarkowanie związane ze wzrostem liczby przestępstw drogowych.

- Korelacja dla przestępstw gospodarczych: -0.4421

Interpretacja: Ujemna korelacja (-0.4421) sugeruje, że istnieje odwrotny związek pomiędzy stopą bezrobocia a liczbą przestępstw gospodarczych. Wzrost stopy bezrobocia jest związany ze spadkiem liczby przestępstw gospodarczych, choć związek ten nie jest bardzo silny.

```

# Podział danych na grupy
niskie_bezrobocie = df_merged[df_merged["Bezrobocie [%]"] < df_merged["Bezrobocie [%]"].median
()]
wysokie_bezrobocie = df_merged[df_merged["Bezrobocie [%]"] >= df_merged["Bezrobocie [%]"].median
()]

# Test t-Studenta dla przestępstw kryminalnych
t_stat_kryminalne, p_value_kryminalne = ttest_ind(niskie_bezrobocie["Liczba przestępstw
kryminalnych"], wysokie_bezrobocie["Liczba przestępstw kryminalnych"])

t_stat_kryminalne = round(t_stat_kryminalne, 4)
p_value_kryminalne = round(p_value_kryminalne, 4)

print(f"T-statystyka - przestępstwa kryminalne: {t_stat_kryminalne}, p-wartość:
{p_value_kryminalne}")

# Test t-Studenta dla przestępstw drogowych
t_stat_drogowe, p_value_drogowe = ttest_ind(niskie_bezrobocie["Liczba przestępstw drogowych"],
wysokie_bezrobocie["Liczba przestępstw drogowych"])

t_stat_drogowe = round(t_stat_drogowe, 4)
p_value_drogowe = round(p_value_drogowe, 4)

print(f"T-statystyka - przestępstwa drogowe: {t_stat_drogowe}, p-wartość: {p_value_drogowe}")

# Test t-Studenta dla przestępstw gospodarczych
t_stat_gospodarcze, p_value_gospodarcze = ttest_ind(niskie_bezrobocie["Liczba przestępstw
gospodarczych"], wysokie_bezrobocie["Liczba przestępstw gospodarczych"])

t_stat_gospodarcze = round(t_stat_gospodarcze, 4)
p_value_gospodarcze = round(p_value_gospodarcze, 4)

print(f"T-statystyka - przestępstwa gospodarcze: {t_stat_gospodarcze}, p-wartość:
{p_value_gospodarcze}")

```

Test t-studenta

Przestępstwa kryminalne:

- T-statystyka: -3.776
- P-wartość: 0.0012

Interpretacja: Niska p-wartość (<0.05) wskazuje na statystycznie istotną różnicę w liczbie przestępstw kryminalnych między okresami niskiego i wysokiego bezrobocia. Wynik sugeruje, że zmienność w bezrobociu ma istotny wpływ na liczbę przestępstw kryminalnych.

Przestępstwa drogowe:

- T-statystyka: -2.6607
- P-wartość: 0.015

Interpretacja: Niska p-wartość (<0.05) sugeruje, że istnieje statystycznie istotna różnica w liczbie przestępstw drogowych między okresami niskiego i wysokiego bezrobocia. Wskazuje to, że stopa bezrobocia ma istotny wpływ na przestępczość drogową.

Przestępstwa gospodarcze:

- T-statystyka: 1.6324
- P-wartość: 0.1182


Interpretacja: Wysoka p-wartość (>0.05) wskazuje, że nie ma statystycznie istotnej różnicy w liczbie przestępstw gospodarczych między okresami niskiego i wysokiego bezrobocia. Sugeruje to, że zmiany w stopie bezrobocia nie mają istotnego wpływu na przestępczość gospodarczą.

Prognozowanie:


Model Arima dla przestępczości kryminalnej:

- ADF Statistic: -2.669358
- p-value: 0.079492
- Critical Values:
- 1%: -4.01203360058309
- 5%: -3.1041838775510207
- 10%: -2.690987346938775

Dane o liczbie przestępstw kryminalnych nie są w pełni stacjonarne, co sugeruje, że mogą być pod wpływem trendów lub sezonowości. Na początku dane miały inną postać, natomiast po pierwszym różnicowaniu przybrały postać taką, jak widać wyżej w punktach co pozwoliło odrzucić hipotezę zero.



Wykresy ACF i PACF sugerują, że w danych występuje krótkoterminowa autokorelacja. Obecność istotnych lagów w ACF i PACF wskazuje, że model ARIMA może być odpowiedni do modelowania tych danych.




Model ARIMA(1, 1, 1) został dopasowany do danych o liczbie przestępstw kryminalnych. Po dopasowaniu modelu, przeprowadzono prognozowanie na 5 kolejnych okresów. Prognozowane wartości pokazują niewielki wzrost liczby przestępstw kryminalnych w kolejnych latach. Prognoza wydaje się stabilna, bez dużych wahań, co sugeruje, że model dobrze dopasowuje się do historycznych danych.

Model Arima dla przestępstwa gospodarczego:


- ADF Statistic: -5.224548
- p-value: 0.000008
- Critical Values:
- 1%: -4.223238279489106
- 5%: -3.189368925619835
- 10%: -2.729839421487603

Ponieważ p-value (0.000008) jest znacznie mniejsze niż 0.05, możemy odrzucić hipotezę zerową na poziomie istotności 5%. Oznacza to, że dane o liczbie przestępstw gospodarczych są stacjonarne.

Krytyczne wartości są bardziej negatywne niż ADF Statistic, co również sugeruje, że dane są stacjonarne.
Zostało przeprowadzone różnicowanie trzykrotne i dzięki temu dane zostały stacjonarne



Obecność istotnych lagów w ACF i PACF wskazuje, że model ARIMA może być odpowiedni do modelowania tych danych




Model ARIMA(1, 3, 2) został dopasowany do danych o liczbie przestępstw gospodarczych. Prognozowane wartości pokazują wyraźny wzrost liczby przestępstw gospodarczych w kolejnych latach. Prognoza sugeruje trend wzrostowy, co może wynikać z utrzymujących się trendów w danych.

Model Arima dla przestępstw drogowych:

- ADF Statistic: -3.892738
- p-value: 0.002089
- Critical Values:
- 1%: -3.8092091249999998
- 5%: -3.0216450000000004
- 10%: -2.6507125

Po pierwszym zróżnicowaniu mogliśmy odrzucić hipotezę zerową z uwagi na fakt, że p-value (0.002089) jest znacznie mniejsze niż 0.05.

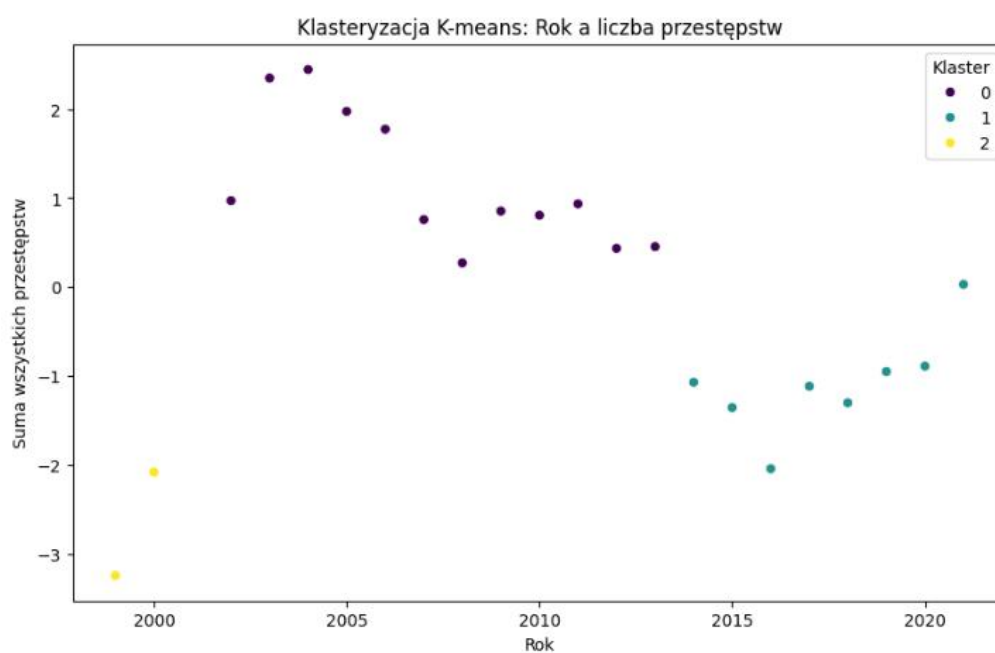


Wykresy ACF i PACF sugerują, że w danych występuje krótkoterminowa autokorelacja.



Model ARIMA(1, 1, 2) został dopasowany do danych o liczbie przestępstw drogowych. Prognozowane wartości pokazują stabilizację liczby przestępstw drogowych w kolejnych latach. Prognoza sugeruje brak istotnych zmian, co może oznaczać, że liczba przestępstw drogowych utrzyma się na stałym poziomie. Brak istotnych zmian w prognozach może sugerować, że obecne działania prewencyjne i regulacje drogowe są skuteczne w utrzymaniu liczby przestępstw drogowych na stałym poziomie.

Analiza korelacji



Wykres przedstawia wyniki klasteryzacji K-średnich liczby przestępstw w Polsce na przestrzeni lat. Na osi X znajdują się lata, a na osi Y suma wszystkich przestępstw. Klasteryzacja podzieliła dane na trzy klastry, oznaczone różnymi kolorami (0 - fioletowy, 1 - zielony, 2 - żółty).

Klaster 0 (Fioletowy) - Okres: 2000 - 2010

Charakterystyka: Wysoka liczba przestępstw, stopniowy spadek. W tym okresie liczba przestępstw była wyższa. Początkowe lata wykazują najwyższą liczbę przestępstw, która stopniowo maleje w ciągu dekady.

Klaster 1 (Zielony) - Okres: 2011 - 2020

Charakterystyka: Średnia liczba przestępstw, trend spadkowy z powolnym wzrostem w ostatnich latach. W tej grupie liczba przestępstw była niższa w porównaniu do Klastera 0. Widać ogólny trend spadkowy, który utrzymuje się do około 2015 roku, po czym następuje powolny wzrost do 2020 roku.

Klaster 2 (Żółty) - Okres: 1999 - 2001

Charakterystyka: Najniższa liczba przestępstw. W tej grupie lata charakteryzują się najniższą liczbą przestępstw. Może to być wynik specyficznych działań policyjnych lub innych czynników wpływających na niską przestępczość w tym okresie.

5. Wnioski

Raport „Analiza wpływu bezrobocia na przestępczość w Polsce” przedstawia kompleksową analizę związku między stopą bezrobocia a poziomem przestępczości, w tym przestępczości kryminalnej, gospodarczej i drogowej, w latach 1999-2021. Płynące wnioski z raportu można zapisać w następujący sposób:

1. Bezrobocie: Dane historyczne pokazują, że stopa bezrobocia w Polsce miała tendencję spadkową z okresowymi wzrostami. Średnia stopa bezrobocia wynosiła 12,18%, z najwyższymi wartościami w latach 2002-2003 i najniższymi w latach 2008 oraz 2015.

2. Przestępczość Kryminalna: Liczba przestępstw kryminalnych w Polsce systematycznie malała od 1999 do 2021 roku, co wskazuje na poprawę bezpieczeństwa publicznego. Średnia roczna liczba przestępstw wynosiła 774955. Modele statystyczne wykazały słabą korelację między stopą bezrobocia a liczbą przestępstw kryminalnych (R^2 : 0.082), ale wysoka dodatnia korelacja Pearsona (0.8513) sugeruje, że wyższe bezrobocie jest powiązane ze wzrostem liczby przestępstw kryminalnych.

3. Przepępczość Gospodarcza: Liczba przepępstw gospodarczych wykazywała tendencję wzrostową, zwłaszcza od 2015 roku, ze średnią liczbą przepępstw na poziomie 149595. Analizy statystyczne nie wykazały istotnego wpływu bezrobocia na przepępczość gospodarczą (R^2 : -0.599, korelacja Pearsona: -0.4421), co sugeruje, że inne czynniki mogą mieć większy wpływ na ten typ przepępczości.

4. Przepępczość Drogowa: Liczba przepępstw drogowych osiągnęła szczyt w latach 2004-2005, a następnie stopniowo malała. Średnia roczna liczba przepępstw wynosiła 121076. Modele regresji liniowej wykazały bardzo słabe dopasowanie do danych (R^2 : -0.5404), ale średnia dodatnia korelacja Pearsona (0.603) wskazuje na umiarkowany związek między stopą bezrobocia a liczbą przepępstw drogowych.

5. Modelowanie i Prognozowanie: Modele ARIMA wykazały, że liczba przepępstw kryminalnych i gospodarczych może wzrosnąć w przyszłości, natomiast liczba przepępstw drogowych prawdopodobnie pozostanie stabilna. Analizy sugerują, że obecne działania prewencyjne są skuteczne w utrzymaniu liczby przepępstw drogowych na stałym poziomie.

Wnioski raportu wskazują na istotną zależność między bezrobociem a niektórymi typami przepępczości w Polsce, podkreślając potrzebę zintegrowanych strategii politycznych i społecznych w celu dalszej poprawy bezpieczeństwa publicznego oraz zmniejszenia bezrobocia. Analiza raportu sugeruje, że przyszłość Polski w kontekście bezrobocia i przepępczości może być złożona. Choć bezrobocie wykazuje tendencję spadkową, wzrost przepępczości gospodarczej oraz stabilizacja przepępstw drogowych wskazują na konieczność dalszych działań prewencyjnych i edukacyjnych. Prognozy sugerują, że bezrobocie może nadal wpływać na przepępczość kryminalną, zwłaszcza w regionach o wyższych wskaźnikach bezrobocia. Wzrost gospodarczy, rozwój infrastruktury oraz zwiększenie dostępności miejsc pracy mogą przyczynić się do dalszego spadku przepępczości kryminalnej. Kluczowe będzie również monitorowanie i adaptacja polityk społecznych oraz prawnych, aby skutecznie przeciwdziałać rosnącym wyzwaniom związanym z przepępczością gospodarczą.